



RECUNOASTERE DE IMAGINI





Contine "S"

Nu contine "S"

Descrierea Aplicatiei - 1


- -> Fiecare poza este construita in formatul 10px * 10px => 100px
- -> Un set de imagini este construit astfel incat sa contina litera S
- -> Alt set este construit astfel incat sa nu contina litera S
- -> Fiecare poza este citita in MATLAB si stocata in cadrul unei matrici, iar matricea este convertita intr-un vector linie
- -> Informatia pentru fiecare pixel este un numar de la 0 la 255 (UINT8), 255 insemnand alb iar 0 negru complet

Descrierea Aplicatiei - 2


- -> Realizam un program care "invata" din cele 2 seturi de imagini si care ulterior decide daca o imagine furnizata ca si test contine sau nu litera "S"
- -> Am implementat solutia SVM folosind CVX, dupa care am incercat sa implementam o solutie sub forma Regresiei Logistice (asemanator cu Laboratorul 2)

Formularea matematica a problemei - 1

- -> Tehnica SVM se bazeaza pe gasirea unui hiperplan de separare a doua clase de obiecte
- -> Hiperplanul este definit de H = {z ∈ R^n: w'z = b} caracterizat de parametrii w ∈ R^n si b ∈ R.
- -> Trebuie, deci, sa gasim parametrii optimi w si b



Formularea matematica a problemei-2



- -> distanta intre cele doua hiperplane este 2 / ||w|| si vrem sa fie maxima
- -> reformulam problema astfel incat sa fie QP
- -> variabila de decizie este x=[w' b]'


$$\begin{cases} w^T z_i - b \ge 1, \ \forall y_i = 1 \\ w^T z_j - b \le -1, \ \forall y_j = -1 \end{cases} \Rightarrow \begin{cases} y_i (w^T z_i - b) \ge 1, \ i = 1 : n_1 \\ y_j (w^T z_j - b) \ge 1, \ j = 1 : n_2 \end{cases}$$

$$\begin{aligned} \max_{w,b} \frac{2}{\|w\|} & \Leftrightarrow & \min_{w,b} \frac{\|w\|^2}{2} \\ \text{s.l.: } y(w^T z - b) \ge 1 & \text{s.l.: } y(w^T z - b) \ge 1 \end{aligned}$$

Solutia implementata

%% Imagini care contin diferite variatii ale literei S

```
A = imread('s1.png'); %citeste imaginea
B1 = rgb2gray(A); %conversie in gray
B1 = reshape(B1.',1,[]); %conversie din matrice in vector linie
A = imread('s2.png');
B2 = rgb2gray(A);
B2 = reshape(B2.', 1, []);
A = imread('s3.png');
B3 = rgb2gray(A);
B3 = reshape(B3.',1,[]);
A = imread('s4.png');
B4 = rgb2gray(A);
B4 = reshape(B4.',1,[]);
A = imread('s5.png');
B5 = rgb2gray(A);
B5 = reshape(B5.', 1, []);
A = imread('s6.png');
B6 = rgb2gray(A);
B6 = reshape(B6.', 1, []);
A = imread('s7.png');
B7 = rgb2gray(A);
B7 = reshape(B7.',1,[]);
A = imread('s8.png');
B8 = rgb2gray(A);
B8 = reshape(B8.', 1, []);
A = imread('s9.png');
B9 = rgb2gray(A);
B9 = reshape(B9.', 1, []);
```



```
A = imread('s10.png');
B10 = rgb2gray(A);
B10 = reshape(B10.', 1, []);
A = imread('s11.png');
B11 = rgb2gray(A);
B11 = reshape(B11.',1,[]);
A = imread('s12.png');
B12 = rgb2gray(A);
B12 = reshape(B12.',1,[]);
A = imread('s13.png');
B13 = rgb2gray(A);
B13 = reshape(B13.', 1, []);
C1=[B1;B2;B3;B4;B5;B6;B7;B8;B9;B10;B11;B12;B13];
C1=double(C1);
%% Imagini random diferite de S
A = imread('n1.png');
B1 = rgb2gray(A);
B1 = reshape(B1.',1,[]);
A = imread('n2.png');
B2 = rgb2gray(A);
B2 = reshape(B2.',1,[]);
A = imread('n3.png');
B3 = rgb2gray(A);
B3 = reshape(B3.',1,[]);
A = imread('n4.png');
B4 = rgb2gray(A);
B4 = reshape(B4.', 1, []);
```

n1.png

```
A = imread('n5.png');
B5 = rgb2gray(A);
B5 = reshape(B5.', 1, []);
A = imread('n6.png');
B6 = rgb2gray(A);
B6 = reshape(B6.', 1, []);
A = imread('n7.png');
B7 = rgb2gray(A);
B7 = reshape(B7.', 1, []);
A = imread('n8.png');
B8 = rgb2gray(A);
B8 = reshape(B8.', 1, []);
A = imread('n9.png');
B9 = rgb2gray(A);
B9 = reshape(B9.', 1, []);
A = imread('n10.png');
B10 = rgb2grav(A);
B10 = reshape(B10.', 1, []);
A = imread('n11.png');
B11 = rgb2gray(A);
B11 = reshape(B11.',1,[]);
A = imread('n12.png');
B12 = rgb2gray(A);
B12 = reshape(B12.',1,[]);
A = imread('n13.png');
B13 = rgb2gray(A);
B13 = reshape(B13.',1,[]);
```


```
C2=[B1;B2;B3;B4;B5;B6;B7;B8;B9;B10;B11;B12;B13];
C2=double(C2);
```

```
%% CVX

cvx_begin
variable w(100);
variable b(1);
minimize ((1/2)*w'*w)
subject to
C1*w-b*ones(13,1)>=ones(13,1); %1*C1*.. >=
C2*w-b*ones(13,1)<=-ones(13,1); % -1*C2*... >=
cvx_end
```

```
%% Testare
disp 'Test CVX'
A=imread('t1.png');
A=rgb2gray(A);
A = reshape(A.',1,[]);
A=double(A);
rez1 = w'*A'-b;
if (rez1 > 0)
    disp 'Prima imagine test contine S'
else
    disp 'Prima imagine test nu contine S'
end
A=imread('t2.png');
A=rgb2gray(A);
A = reshape(A.',1,[]);
A=double(A);
rez2 = w'*A'-b;
if (rez2 > 0)
    disp 'A doua imagine test contine S'
else
    disp 'A doua imagine test nu contine S'
end
```





Test CVX

Prima imagine test contine S

A doua imagine test nu contine S

Regresia logistică

Scop: Modelarea probabilitatii ca o variabila aleatoare(imaginea pe care noi o furnizam) sa apartina hiperplanului in care avem imaginile care contin S sau sa apartina hiperplanului in care avem imaginile care nu contin S. Deci obtinem probabilitatea, si cu ajutorul acesteia mapam imaginea nostra in una dintre cele doua clase.

Functia sigmoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Practic, cu ajutorul acestei functii vom realiza maparea intre o predictie(o valoare reala) si o probabilitate(O sau 1).

Cu ajutorul functiei sigmoid, putem afla:

-> probabilitatea ca o imagine sa contina S:


P(class = 1 | X,w) =
$$\frac{1}{1 + e^{-w^T X}} = \sigma(w^T X) = h_w(X)$$

->probabilitatea ca o imagine sa nu contina S:

P(class=0|X,w) = 1 -
$$\frac{1}{1 + e^{-w^T X}}$$
 = 1 - $\sigma(w^T X)$ = 1 - $h_w(X)$

Practic, daca o valoare a unei probabilitati, P(class|X,w), este >= 0.5 atunci putem face maparea in clasa imaginilor care contin S. Același raționament și pentru cazul invers.

Suma celor doua probabilitati este mereu 1!



Valoarea de prag

$$p \ge 0.5, \ \ y = 1 \ p < 0.5, \ \ y = 0.$$
 y=class

Pe masura ce probabilitatea se apropie de 1, modelul nostru este mai sigur ca observatia se afla in clasa 1.

In cazul nostru:

X_i = [C_{1,i} C_{2,i} C_{3,i...}C_{100,i} 1]' %reprezinta datele asociate unei imagini ->**le stim** (sunt date)

w = [w₁ w₂ w₃...w₁₀₁] %parametrii de regresie-> **trebuie aflate**

Introducem functia likelihood:

$$L(w|y,x) = P(Y|X,w) = \prod_{i=1}^{N} P(y_i|x_i,w)$$

$$= \prod_{i=1}^{N} h_w(x_i)^{y_i} (1 - h_w(x_i))^{(1-y_i)}.$$
Aplicăm **log**

Pentru a afla parametrii de regresie(w) trebuie sa **maximizam** urmatoarea functie:

$$\frac{1}{N} \log L(w|y, x) = \frac{1}{N} \sum_{i=1}^{N} \log P(y_i|x_i, w)$$

$$= \frac{1}{N} \sum_{i=1}^{N} \left[y^{(i)} \log \left(h_w(x^{(i)}) \right) + \left(1 - y^{(i)} \right) \log \left(1 - h_w(x^{(i)}) \right) \right] \tag{2}$$

Sau sa minimizam:

$$F(w) = -\frac{1}{N} \sum_{i=1}^{N} \left[y^{(i)} \log \left(h_w \left(x^{(i)} \right) \right) + \left(1 - y^{(i)} \right) \log \left(1 - h_w \left(x^{(i)} \right) \right) \right]$$
$$= \frac{1}{N} \cdot \left(-y^T \log(h) - (1 - y)^T \log(1 - h) \right),$$

Acel minus apare pentru ca vom minimiza functia. Stim ca:

$$\max_{x} f(x) = -\min_{x} -f(x).$$

Aplicam Metoda Gradient cu pas ideal


$$\frac{\partial F(w)}{\partial w_j} = \frac{1}{N} \sum_{i=1}^{N} \left(h_w(x_i) - y_i \right) x_i^j \quad \Rightarrow \quad \nabla F(w) = \frac{1}{N} (h - y)^T X.$$

```
%% Regresie logistica
n=26; %nr de poze
C1=C1'; %aduc informatia despre o poza de la forma linie la forma coloana
C2=C2';
pixeli=[C2 C1; ones(1,26)]; %matricea cu pixeli
y=[zeros(13,1);ones(13,1)]; %etichetele
[m, ~] = size(pixeli); %nr parametrilor de regresie
epsilon = 0.001; % marja eroarea
maxIter = 100000; % nr maxim de iteratii
wr=zeros(m,1); %w gasit cu regresie logistica
%Metoda Gradient
%Calculam gradientul functiei
F=\emptyset(wr)(1/n)*(-y'*log(sigmoid(pixeli'*wr))-(ones(n,1)-y)'*log(1-sigmoid(pixeli'*wr)));
gradient=(1/n)*pixeli*(sigmoid(pixeli'*wr)-y);
```


```
%Metoda Gradient cu pas ideal
k=0;
norma=norm(gradient);
norm init=norma;
ngpi=[]; %vectorul cu norme pt metoda gradient cu pas constant
ngpi=[ngpi;norma];
while (norma>=epsilon && k<maxIter)</pre>
    cost=@(alfa) F(wr-alfa*gradient);
    alfa=fminbnd(cost,0,1); %pasul ideal
    wr=wr-alfa*gradient;
    gradient=(1/n)*pixeli*(sigmoid(pixeli'*wr)-y);
    norma=norm(gradient);
    ngpi=[ngpi;norma];
    k=k+1;
end
wgpi=wr; %salvam w pt metoda gradient pas ideal
```

%% Testare Regresie logistica

```
disp 'Test Regresie Logistica'
prag decizie=0.5;
A=imread('t3.png');
A=rgb2gray(A);
A = reshape(A.', 1, []);
A=double(A);
A = [A \ 1];
if (sigmoid(wr'*A') >= prag decizie)
    disp 'Imaginea contine S';
else.
    disp 'Imaginea nu contine S';
end
A=imread('t4.png');
A=rgb2gray(A);
A = reshape(A.',1,[]);
A=double(A);
A = [A \ 1];
if (sigmoid(wr'*A') >= prag decizie)
    disp 'Imaginea contine S';
else
    disp 'Imaginea nu contine S';
end
```



Test Regresie Logistica Imaginea contine S Imaginea nu contine S



Evolutia normei gradientului

Referinte

- Culegere TO
- Curs
- Indrumar laborator

VA MULTUMIM!